

TRƯỜNG ĐẠI HỌC KINH TẾ - KỸ THUẬT CÔNG
NGHIỆP HÀ NỘI
KHOA KHOA HỌC ỨNG DỤNG



BÀI TẬP NHÓM SỐ 1
MÔN: ĐỒ ÁN 2

BÀI BÁO CÁO :

**Xây dựng Hệ khuyến nghị Sản phẩm Dược
phẩm từ Dữ liệu Website Pharmacy**

GV hướng dẫn: Lê Hằng Anh

Nhóm sinh viên thực hiện:

<i>Họ và tên</i>	<i>MSSV</i>	<i>Lớp</i>
Lê Văn Đức	23174600097	DHKL17A2HN
Trần Văn Hoà	23174600088	DHKL17A2HN
Trần Thị Thanh Thư	23174600085	DHKL17A2HN

Hà Nội, 2026

Mục lục

1	Giới thiệu	2
2	Mô tả bài toán	2
2.1	Bối cảnh	2
2.2	Mục tiêu nghiên cứu	3
2.3	Phương pháp thực hiện	3
3	Mô tả bộ dữ liệu	3
3.1	Tổng quan	3
3.2	Mô tả chi tiết các cột	4
3.3	Phân loại dữ liệu	4
3.4	Nhận xét dữ liệu	4
4	Tiền xử lý dữ liệu	5
5	Kết luận	5

1 Giới thiệu

Trong khoảng vài năm trở lại đây, thương mại điện tử tại Việt Nam phát triển rất nhanh và dần trở thành một phần quen thuộc trong đời sống. Đặc biệt sau giai đoạn dịch COVID-19 (2020), thói quen mua sắm trực tuyến của người dùng ngày càng phổ biến hơn nhờ sự tiện lợi và dễ tiếp cận thông qua điện thoại thông minh.

Không chỉ các mặt hàng tiêu dùng thông thường, lĩnh vực bán lẻ dược phẩm cũng không nằm ngoài xu hướng. Các chuỗi nhà thuốc hiện đại như Pharmacity đã triển khai nền tảng bán hàng trực tuyến, cung cấp đa dạng các sản phẩm như thuốc, thực phẩm chức năng và các sản phẩm chăm sóc sức khỏe. Điều này tạo ra một nguồn dữ liệu phong phú, có giá trị cho việc phân tích và khai thác thông tin.

Trong bài báo cáo này, nhóm thực hiện thu thập dữ liệu sản phẩm từ website Pharmacity bằng các công cụ hỗ trợ như Selenium và BeautifulSoup. Sau khi thu thập, dữ liệu được tổng hợp và xử lý lại để có thể sử dụng cho việc phân tích, cũng như làm nền tảng cho các bài toán liên quan đến học máy hoặc phân tích dữ liệu trong tương lai.

2 Mô tả bài toán

Bài toán đặt ra là:

Xây dựng hệ khuyến nghị các sản phẩm dược phẩm tương tự dựa trên đặc điểm nội tại của sản phẩm như hoạt chất, quy cách, thương hiệu và giá bán.

Hệ khuyến nghị này cho phép:

Gợi ý thuốc thay thế khi sản phẩm không còn hàng. Gợi ý sản phẩm có đặc điểm tương tự nhưng giá phù hợp hơn. Nhóm các sản phẩm có tính chất gần nhau.

Bài toán này không nhằm mục tiêu dự đoán hay phân loại, mà tập trung vào việc đo lường độ tương đồng giữa các sản phẩm.

2.1 Bối cảnh

Hiện nay, các website bán lẻ dược phẩm như Pharmacity cung cấp rất nhiều thông tin về sản phẩm, bao gồm tên, giá, hoạt chất, thương hiệu và quy cách đóng gói. Tuy nhiên, dữ liệu này thường chỉ hiển thị

trên website và chưa được tổ chức thành dạng bảng để dễ dàng phân tích.

Vì vậy, việc thu thập và chuyển đổi dữ liệu từ website sang dạng có cấu trúc là cần thiết để phục vụ cho các mục đích như phân tích giá, so sánh sản phẩm hoặc nghiên cứu dữ liệu.

2.2 Mục tiêu nghiên cứu

Từ bộ dữ liệu sản phẩm thu thập được, nhóm hướng tới các mục tiêu chính sau:

Xây dựng bộ dữ liệu được phẩm có cấu trúc từ website Pharmacy.

Làm sạch, chuẩn hóa và trích xuất các thuộc tính quan trọng của sản phẩm như hoạt chất, quy cách, thương hiệu và giá.

Biểu diễn mỗi sản phẩm dưới dạng tập đặc trưng số và văn bản phục vụ tính toán độ tương đồng.

Xây dựng phương pháp đo lường độ tương đồng giữa các sản phẩm.

Thiết kế và triển khai hệ khuyến nghị sản phẩm tương tự dựa trên học không giám sát (Content-based Recommender System).

Minh họa khả năng gợi ý sản phẩm thay thế dựa trên kết quả tính toán độ tương đồng.

2.3 Phương pháp thực hiện

Nhóm sử dụng ngôn ngữ Python và thư viện `requests` để thu thập dữ liệu từ website Pharmacy thông qua API. Dữ liệu được trả về dưới dạng CSV, giúp việc xử lý và trích xuất thông tin trở nên thuận tiện hơn.

Việc sử dụng API giúp quá trình thu thập dữ liệu diễn ra nhanh và ổn định hơn so với việc lấy dữ liệu trực tiếp từ giao diện website.

3 Mô tả bộ dữ liệu

3.1 Tổng quan

Dữ liệu được thu thập từ website Pharmacy thông qua API và lưu dưới dạng file CSV.

Tập dữ liệu gồm khoảng 4900 dòng (tương ứng với 4900 sản phẩm) và 6 cột (thuộc tính).

Khối lượng dữ liệu này đủ để phục vụ cho việc phân tích các thông tin như giá, thương hiệu và thành phần sản phẩm.

3.2 Mô tả chi tiết các cột

Tập dữ liệu gồm 6 thuộc tính chính, mỗi thuộc tính biểu diễn một đặc điểm của sản phẩm. Bảng dưới đây mô tả chi tiết các thuộc tính trong tập dữ liệu:

Thuộc tính	Mô tả	Kiểu	Ví dụ
Tên sản phẩm	Tên đầy đủ của sản phẩm	String	Paracetamol STADA 500mg
Giá bán	Giá của sản phẩm	Số	25000
Hoạt chất	Thành phần chính	String	Paracetamol
Thương hiệu	Hãng sản xuất	String	DHG Pharma
Quy cách	Dạng đóng gói	String	Hộp 10 vỉ x 10 viên
Liên kết	Trang sản phẩm	String	pharmacity.vn/product/...

Mỗi dòng trong bảng dữ liệu tương ứng với một sản phẩm. Các thông tin này được lấy trực tiếp từ dữ liệu trả về của API và giữ nguyên để phục vụ cho việc phân tích sau này.

3.3 Phân loại dữ liệu

Trong tập dữ liệu, đa số các cột là dạng văn bản như tên sản phẩm, hoạt chất, thương hiệu, quy cách và đường dẫn.

Riêng cột giá là dạng số, tuy nhiên khi lấy về vẫn cần xử lý lại để có thể dùng cho việc tính toán hoặc phân tích sau này.

3.4 Nhận xét dữ liệu

Dữ liệu sơ bộ vẫn tồn tại một số hạn chế như giá trị thiếu (Missing values) ở các thuộc tính quan trọng và định dạng dữ liệu chưa đồng nhất. Cột giá thì có nhưng chưa ở dạng số hoàn toàn nên nhóm đã phải xử lý lại để thuận tiện cho quá trình phân tích và nghiên cứu sau này.

Dữ liệu nhìn khá rõ ràng, không bị rối và số lượng trùng lặp cũng không đáng kể. Tuy vậy, trước khi sử dụng để phân tích thì nhóm đã kiểm tra và xử lý lại để dữ liệu được sạch hơn.

4 Tiền xử lý dữ liệu

Trong quá trình thu thập dữ liệu, nhóm đã thực hiện kiểm tra và loại bỏ trùng lặp ngay từ bước crawl thông qua mã sản phẩm (SKU).

Listing 1: Đoạn code đã sử dụng để loại bỏ trùng lặp theo SKU

```
seen = set()

for item in items:
    sku = item.get("sku")

    if not sku or sku in seen:
        continue

    seen.add(sku)

    name = item.get("name")
    price = item.get("variants", [{}])[0].get("price", "")
    brand = item.get("brand_name")

    data_csv.append([name, price, brand])
```

Đoạn code trên thực hiện việc kiểm tra và loại bỏ các sản phẩm trùng lặp dựa trên mã SKU trong quá trình thu thập dữ liệu. Cách làm này khá đơn giản nhưng hiệu quả, giúp đảm bảo mỗi sản phẩm chỉ xuất hiện một lần trong tập dữ liệu.

Việc sử dụng cấu trúc `set` để lưu trữ các SKU đã gặp giúp kiểm tra trùng lặp nhanh và tiết kiệm thời gian. Ngoài ra, việc loại bỏ ngay từ bước crawl cũng giúp giảm bớt công việc xử lý dữ liệu ở các bước sau.

5 Kết luận

Trong bài báo cáo này, nhóm đã thực hiện thu thập dữ liệu sản phẩm từ website Pharmacy thông qua API và xây dựng được một tập dữ liệu gồm các thông tin cơ bản như tên sản phẩm, giá, hoạt chất, thương hiệu và quy cách.

Sau khi thu thập, dữ liệu đã được xử lý lại để có thể sử dụng cho việc phân tích. Qua quá trình thực hiện, nhóm hiểu rõ hơn về cách làm

việc với dữ liệu thực tế, từ bước lấy dữ liệu cho đến xử lý và tổ chức lại dữ liệu.